산탄데르 고객 만족도 분석 보고서

데이터 전처리와 앙상블 학습을 통한 고객만족도 예측

2025 APRIL 14

우 성 욱

<목 차>

0. 요약

본 보고서는 산탄데르 은행에서 제공한 고객 만족도 데이터셋을 분석하여 불만족 고객을 사전에 식별하고 고객 이탈을 방지하기 위한 예측 모델을 개발한 과정과 결과를 담고 있습니다. 극심한 클래스 불균형, 이상치 존재, 370개의 특성을 가진 고차원 데이터와 같은 여러 과제를 해결하는 과정에서 다양한 전처리 기법과 모델링 접근법을 테스트했으며, 이상치 제거와 SMOTE 조합이 가장 우수한 성능을 보였습니다.

1. 프로젝트 개요

1.1. 목표

- 고객 만족 여부를 예측하여 불만족 고객을 사전에 식별
- 식별된 고객에 대한 조치를 통해 이탈 방지에 활용

1.2. 데이터

- Santander 은행에서 제공한 고객 만족도 데이터 셋

  (https://www.kaggle.com/competitions/santander-customer-satisfaction)

1.3. 주요 과제

- 극심한 클래스 불균형 처리
- 이상치 존재로 이상치 미처리 및 처리 비교

2. 데이터 구성

2.1. 데이터 구성

파일명	*샘플 수*	*설명*
train.csv	76,020	학습용 데이터, Target 값 포함
test.csv	75,818	테스트용 데이터, Target 값 미 포함

2.2. 이상치, 결측 치 및 중복 데이터 유무

결측 치	`train 전체 결측치 개수 확인 : 0` `test 전체 결측치 개수 확인 : 0`
이상 치	이상치 존재
중복 데이터	일부 중복 샘플 존재 (모델 성능에 미치는 영향은 미미)

2.3. 클래스 불균형 여부

아래 <Chart 1 Class 불균형>을 참고하면 목표 값(Target)이 불균형 하는 것을 알 수 있습니다. 목표 값의 비율 Target=0이 약 96%와 Target=1의 비율이 약 4%로 구성 되어 있습니다.

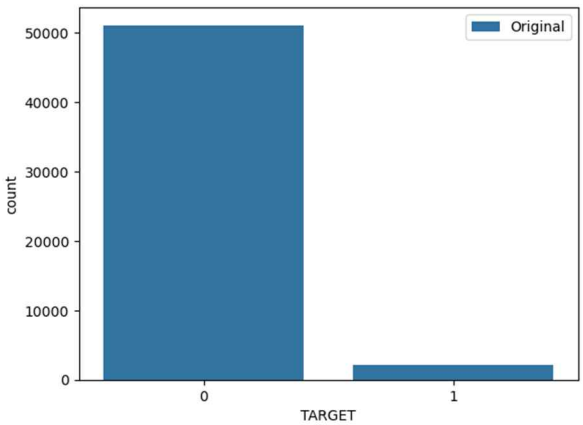

Chart 1 클래스 불균형

3. 데이터 전처리

3.1. 결측 치 및 이상치 처리 방법

5% 이하	최대값, 평균값, 중앙값으로 대체
5% ~ 30%	특정 컬럼 그룹별 평균값, 중앙값으로 대체
30% 이상	삭제하거나 새로운 범주를 생성

	Outlier Count	Outlier Ratio (%)
saldo_var30	15983	21.024730
num_var22_hace2	15479	20.361747
saldo_var42	15281	20.101289
saldo_medio_var5_hace3	14864	19.552749
num_var45_hace2	14196	18.674033
num_var22_hace3	14140	18.600368
num_op_var39_ult3	13776	18.121547
saldo_medio_var5_ult3	13720	18.047882
num_op_var41_ult3	13665	17.975533
saldo_medio_var5_ult1	13146	17.292818
saldo_medio_var5_hace2	13019	17.125756
saldo_var5	12291	16.168114
imp_op_var39_ult1	11749	15.455143
num_op_var39_ult1	11749	15.455143
num_med_var45_ult3	11704	15.395948
num_op_var39_comer_ult3	11690	15.377532
imp_op_var39_comer_ult3	11690	15.377532
imp_op_var41_ult1	11632	15.301237
num_op_var41_ult1	11632	15.301237
num_op_var41_comer_ult3	11540	15.180216
imp_op_var41_comer_ult3	11540	15.180216
num_var22_ult3	11254	14.803999
num_med_var22_ult3	11254	14.803999
num_var45_hace3	11119	14.626414
num_var39_0	11007	14.479084
num_var45_ult1	10721	14.102868
num_var41_0	10622	13.972639
num_op_var39_comer_ult1	9945	13.082084
imp_op_var39_comer_ult1	9945	13.082084

IQR(Interquartile Range) 방식으로 이상치 탐색을 하였을 때, 대부분 데이터들이 5% ~ 30% 사이로 구성 되어 있는 것을 알 수 있습니다. 따라서 이상치 처리를 각 컬럼들의 중앙값으로 대체하여 실행하였습니다.

4. 프로젝트 흐름

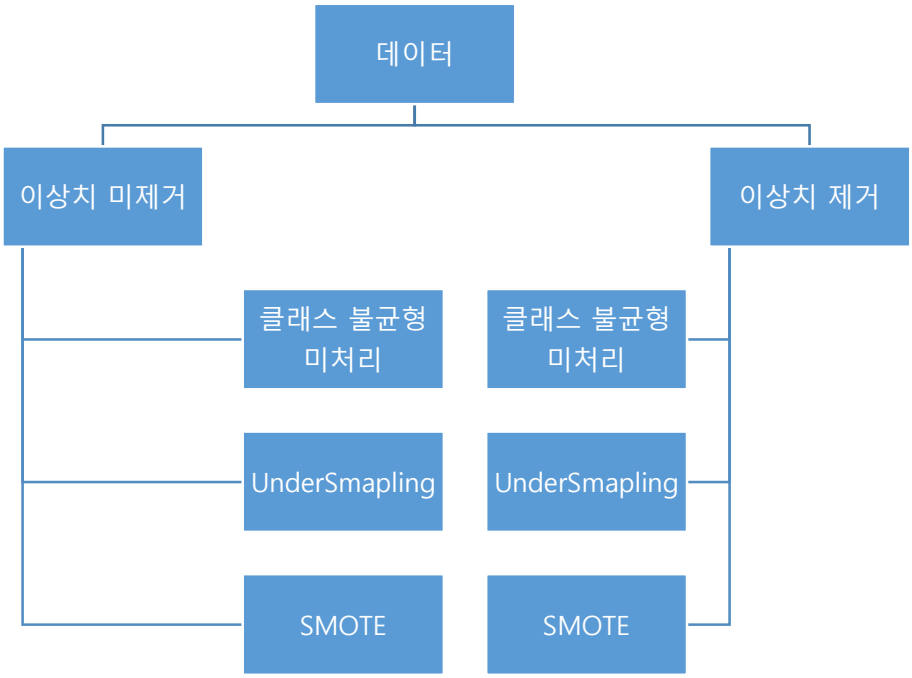
데이터
이상치 미제거
이상치 제거
클래스 불균형 미처리
클래스 불균형 미처리
UnderSmapling
UnderSmapling
SMOTE
SMOTE

5. 모델링

5.1. 사용 모델

- XGBoostClassifier

5.2. 모델 사용한 이유

- 우수한 예측 성능
  테이블 형태의 구조화된 데이터에서 뛰어난 성능을 보이는 알고리즘으로, 많은 데이터 분석 경진대회에서 최상위 성적을 거둠
- 클래스 불균형 처리 능력
  본 데이터 셋의 극심한 클래스 불균형(약 4%)에도 안정적인 성능을 보임
- 고차원 데이터 효과적 처리
  370개 특성을 가진 고차원 데이터에서 자동으로 특성 중요도를 계산하고 중요 변수에 높은 가중치 부여
- 과 적합 방지 메커니즘
  정규화 파라미터와 early stopping 기능을 통해 과 적합 위험 감소
- 계산 효율성
  GPU 가속화(tree_method='gpu_hist')를 통한 빠른 학습 가능
- 해석 가능성
  의사결정나무 기반 모델로서 변수 중요도를 통한 예측 결과 해석 가능

6. 성능 평가 지표(ROC AUC의 중요성)

6.1. 클래스 불균형 문제

- TARGET = 1 비율이 4%로 **극단적으로 불균형**된 상황

6.2. ROC AUC 지표의 장점

- 분류 임계값에 영향을 받지 않음
- 모델의 전체 분류 능력을 측정
- False Positive Rate 와 True Positive Rate 를 모두 고려

7. 실험 결과

실험 명	이상치 처리	클래스 처리	ROC AUC
이상치 미 제거 불균형 미 처리	✕	✕	0.8485
이상치 미 제거 Under Sampling	✕	Under Sampling	0.8362
이상치 미 제거 SMOTE	✕	SMOTE	0.8250
이상치 제거 불균형 미 처리	중앙값으로 대체	✕	0.8297
이상치 제거 Under Sampling	중앙값으로 대체	Under Sampling	0.8198
이상치 제거 SMOTE	중앙값으로 대체	SMOTE	0.9756

8. 전체 코드

Library 로드

```
# ==============================
# 1. 기본 라이브러리 로드
# ==============================
import pandas as pd  # 데이터프레임 처리 라이브러리
import numpy as np  # 수학 연산 및 배열 처리 라이브러리
import matplotlib.pyplot as plt  # 데이터 시각화 라이브러리

# ==============================
# 2. 머신러닝 모델 관련 라이브러리
# ==============================

# (1) 앙상블 학습 모델
from sklearn.ensemble import VotingClassifier  # 여러 개의 분류 모델을 조합하는 투표 기반 앙상블 학습

# (2) 개별 분류 모델
from sklearn.linear_model import LogisticRegression  # 로지스틱 회귀 분류기
from sklearn.neighbors import KNeighborsClassifier  # K-최근접 이웃(KNN) 분류기
from sklearn.ensemble import RandomForestClassifier  # 랜덤 포레스트 분류기
from sklearn.ensemble import GradientBoostingClassifier  # 그래디언트 부스팅 트리 분류기
from sklearn.tree import DecisionTreeClassifier  # 결정 트리 분류기
from sklearn.ensemble import AdaBoostClassifier  # AdaBoost 분류기

# (3) 부스팅 기반 분류 모델 (XGBoost & LightGBM)
import xgboost as xgb  # XGBoost 라이브러리 (트리 기반 부스팅 기법)
from xgboost import XGBClassifier  # XGBoost 분류기
from lightgbm import LGBMClassifier  # LightGBM 분류기

# ==============================
# 3. 모델 평가 및 성능 지표
# ==============================

from sklearn.metrics import confusion_matrix  # 혼동 행렬
from sklearn.metrics import precision_score, recall_score  # 정밀도(precision) 및 재현율(recall)
from sklearn.metrics import f1_score, roc_auc_score  # F1-score 및 ROC-AUC 점수
from sklearn.metrics import accuracy_score  # 분류 모델의 정확도(accuracy)

# ==============================
# 4. 하이퍼파라미터 최적화
# ==============================
```

```
from hyperopt import hp  # 하이퍼파라미터 탐색 공간 정의
from hyperopt import STATUS_OK  # 최적화 과정에서 상태 반환
from hyperopt import fmin, tpe, Trials  # 최적의 하이퍼파라미터 탐색을 위한 함수들

# ==============================
# 5. 데이터셋 로드 및 데이터 분할
# ==============================

from sklearn.datasets import load_breast_cancer  # 유방암 데이터셋 (예제 데이터셋)
from sklearn.model_selection import train_test_split  # 데이터 분할 (학습/테스트 세트)
from sklearn.model_selection import cross_val_score  # 교차 검증을 통한 모델 성능 평가

# ==============================
# 6. 데이터 전처리
# ==============================

from sklearn.preprocessing import StandardScaler  # 데이터 표준화 (평균 0, 분산 1 변환)
from sklearn.preprocessing import MinMaxScaler  # 데이터 Min-Max 스케일링 (0~1 범위 변환)
from sklearn.impute import SimpleImputer  # 결측값 처리
from imblearn.under_sampling import RandomUnderSampler  # 불균형 데이터의 샘플링을 위한 언더샘플링
from imblearn.over_sampling import RandomOverSampler  # 불균형 데이터의 샘플링을 위한 오버샘플링
from imblearn.over_sampling import SMOTE  # SMOTE 기법 (Synthetic Minority Over-sampling Technique)
from scipy.stats import randint  # 범위 내에서 랜덤값 생성

# ==============================
# 7. 통계 분석 관련 라이브러리
# ==============================

from scipy.stats import shapiro, skew, kurtosis  # 데이터 분포 분석을 위한 함수들

from sklearn.model_selection import GridSearchCV  # 그리드 서치를 통한 하이퍼파라미터 최적화
from sklearn.model_selection import RandomizedSearchCV  # 랜덤 서치를 통한 하이퍼파라미터 최적화

import seaborn as sns  # 고급 데이터 시각화 라이브러리

# ==============================
# 8. 기타 유틸리티
# ==============================

import time  # 코드 실행 시간 측정
import warnings  # 경고 메시지 무시 설정
warnings.filterwarnings('ignore')
```

이상치 미 제거 및 불균형 미 처리

```
cust_train_df = pd.read_csv('./santander-customer-satisfaction/train.csv', encoding='latin-1')
cust_test_df = pd.read_csv('./santander-customer-satisfaction/test.csv', encoding='latin-1')

cust_train_copy_df = cust_train_df.copy()
cust_test_copy_df = cust_test_df.copy()

cust_train_copy_df.drop('ID', axis=1, inplace=True)
if 'ID' in cust_test_copy_df.columns:
    ids = cust_test_copy_df['ID']
    cust_test_copy_df.drop('ID', axis=1, inplace=True)
else:
    ids = cust_test_copy_df.index

X_features = cust_train_copy_df.drop('TARGET', axis=1)
y_labels = cust_train_copy_df['TARGET']

X_train, X_test, y_train, y_test = train_test_split(
    X_features, y_labels,
    test_size=0.3,
    random_state=156,
    stratify=y_labels
)

X_tr, X_val, y_tr, y_val = train_test_split(
    X_train, y_train,
    test_size=0.3,
    random_state=0
)

xgb_clf = XGBClassifier(
    n_estimators=500,
    learning_rate=0.05,
    max_depth=5,
    random_state=156,
    eval_metric='auc',
    tree_method='gpu_hist',
    early_stopping_rounds=100,
    gpu_id=0
)

xgb_clf.fit(
    X_tr, y_tr,
    eval_set=[(X_val, y_val)],
    verbose=False
)

roc_score = roc_auc_score(y_test, xgb_clf.predict_proba(X_test)[:, 1])
print(f"ROC AUC Score (이상치 미제거 + 불균형 미처리): {roc_score:.4f}")
```

이상치 미 제거 및 Under Sampling

```
cust_train_df = pd.read_csv('./santander-customer-satisfaction/train.csv', encoding='latin-1')
cust_test_df = pd.read_csv('./santander-customer-satisfaction/test.csv', encoding='latin-1')
cust_train_copy_df = cust_train_df.copy()
cust_test_copy_df = cust_test_df.copy()
cust_train_copy_df.drop('ID', axis=1, inplace=True)
if 'ID' in cust_test_copy_df.columns:
    ids = cust_test_copy_df['ID']
    cust_test_copy_df.drop('ID', axis=1, inplace=True)
else:
    ids = cust_test_copy_df.index

X_features = cust_train_copy_df.drop('TARGET', axis=1)
y_target = cust_train_copy_df['TARGET']

undersample = RandomUnderSampler(random_state=42)
X_resampled, y_resampled = undersample.fit_resample(X_features, y_target)

X_train, X_test, y_train, y_test = train_test_split(
    X_resampled, y_resampled,
    test_size=0.3,
    random_state=156,
    stratify=y_resampled
)

X_tr, X_val, y_tr, y_val = train_test_split(
    X_train, y_train,
    test_size=0.3,
    random_state=0
)

xgb_clf = XGBClassifier(
    n_estimators=500,
    learning_rate=0.05,
    max_depth=5,
    random_state=156,
    eval_metric='auc',
    tree_method='gpu_hist',
    early_stopping_rounds=100,
    gpu_id=0
)
xgb_clf.fit(
    X_tr, y_tr,
    eval_set=[(X_val, y_val)],
    verbose=False
)

roc_score = roc_auc_score(y_test, xgb_clf.predict_proba(X_test)[:, 1])
print(f"ROC AUC Score (이상치 미제거 + 언더샘플링): {roc_score:.4f}")
```

이상치 미 제거 및 SMOTE

```
cust_train_df = pd.read_csv('./santander-customer-satisfaction/train.csv', encoding='latin-1')
cust_test_df = pd.read_csv('./santander-customer-satisfaction/test.csv', encoding='latin-1')

cust_train_copy_df = cust_train_df.copy()
cust_test_copy_df = cust_test_df.copy()

cust_train_copy_df.drop('ID', axis=1, inplace=True)
if 'ID' in cust_test_copy_df.columns:
    ids = cust_test_copy_df['ID']
    cust_test_copy_df.drop('ID', axis=1, inplace=True)
else:
    ids = cust_test_copy_df.index

X_features = cust_train_copy_df.drop('TARGET', axis=1)
y_labels = cust_train_copy_df['TARGET']

X_train, X_test, y_train, y_test = train_test_split(
    X_features, y_labels,
    test_size=0.3,
    random_state=156,
    stratify=y_labels
)

smote = SMOTE(random_state=156)

X_train_over, y_train_over = smote.fit_resample(X_train, y_train)

xgb_clf = XGBClassifier(
    n_estimators=500,
    learning_rate=0.05,
    max_depth=5,
    random_state=156,
    eval_metric='auc',
    tree_method='gpu_hist',
    early_stopping_rounds=100,
    gpu_id=0
)

xgb_clf.fit(
    X_train_over, y_train_over,
    eval_set=[(X_test, y_test)],
    verbose=False
)

roc_score = roc_auc_score(y_test, xgb_clf.predict_proba(X_test)[:, 1])
print(f"ROC AUC Score (이상치 미제거 + SMOTE): {roc_score:.4f}")
```

이상치 제거 및 불균형 미처리

```
cust_train_df = pd.read_csv('./santander-customer-satisfaction/train.csv', encoding='latin-1')
cust_test_df = pd.read_csv('./santander-customer-satisfaction/test.csv', encoding='latin-1')

cust_train_copy_df = cust_train_df.copy()
cust_test_copy_df = cust_test_df.copy()

numeric_cols = cust_train_copy_df.select_dtypes(include=['int64', 'float64']).columns.drop('TARGET')

for col in numeric_cols:
    Q1 = cust_train_copy_df[col].quantile(0.25)
    Q3 = cust_train_copy_df[col].quantile(0.75)
    IQR = Q3 - Q1
    lower_bound = Q1 - 1.5 * IQR
    upper_bound = Q3 + 1.5 * IQR
    median = cust_train_copy_df[col].median()

    cust_train_copy_df.loc[
        (cust_train_copy_df[col] < lower_bound) | (cust_train_copy_df[col] > upper_bound),
        col
    ] = median

cust_train_copy_df.drop('ID', axis=1, inplace=True)
if 'ID' in cust_test_copy_df.columns:
    ids = cust_test_copy_df['ID']
    cust_test_copy_df.drop('ID', axis=1, inplace=True)
else:
    ids = cust_test_copy_df.index

X_features = cust_train_copy_df.drop('TARGET', axis=1)
y_labels = cust_train_copy_df['TARGET']

X_train, X_test, y_train, y_test = train_test_split(
    X_features, y_labels,
    test_size=0.3,
    stratify=y_labels,
    random_state=156
)

X_tr, X_val, y_tr, y_val = train_test_split(
    X_train, y_train,
    test_size=0.3,
    random_state=0
)

xgb_clf = XGBClassifier(
    n_estimators=500,
    learning_rate=0.05,
    max_depth=5,
```

```
    random_state=156,
    eval_metric='auc',
    tree_method='gpu_hist',
    early_stopping_rounds=100,
    gpu_id=0
)

xgb_clf.fit(
    X_tr, y_tr,
    eval_set=[(X_val, y_val)],
    verbose=False
)

roc_score = roc_auc_score(y_test, xgb_clf.predict_proba(X_test)[:, 1])
print(f"ROC AUC Score: {roc_score:.4f}")
```

이상치 제거 및 UnderSampling

```
cust_train_df = pd.read_csv('./santander-customer-satisfaction/train.csv', encoding='latin-1')
cust_test_df = pd.read_csv('./santander-customer-satisfaction/test.csv', encoding='latin-1')

cust_train_copy_df = cust_train_df.copy()
cust_test_copy_df = cust_test_df.copy()

numeric_cols = cust_train_copy_df.select_dtypes(include=['int64', 'float64']).columns.drop('TARGET')

for col in numeric_cols:
    Q1 = cust_train_copy_df[col].quantile(0.25)
    Q3 = cust_train_copy_df[col].quantile(0.75)
    IQR = Q3 - Q1
    lower_bound = Q1 - 1.5 * IQR
    upper_bound = Q3 + 1.5 * IQR
    median = cust_train_copy_df[col].median()

    cust_train_copy_df.loc[
        (cust_train_copy_df[col] < lower_bound) | (cust_train_copy_df[col] > upper_bound),
        col
    ] = median


cust_train_copy_df.drop('ID', axis=1, inplace=True)
if 'ID' in cust_test_copy_df.columns:
    ids = cust_test_copy_df['ID']
    cust_test_copy_df.drop('ID', axis=1, inplace=True)
else:
    ids = cust_test_copy_df.index


X_features = cust_train_copy_df.drop('TARGET', axis=1)
```

```
y_target = cust_train_copy_df['TARGET']

undersample = RandomUnderSampler(random_state=42)
X_resampled, y_resampled = undersample.fit_resample(X_features, y_target)

X_train, X_test, y_train, y_test = train_test_split(
    X_resampled, y_resampled,
    test_size=0.3,
    random_state=156,
    stratify=y_resampled
)

X_tr, X_val, y_tr, y_val = train_test_split(
    X_train, y_train,
    test_size=0.3,
    random_state=0
)


xgb_clf = XGBClassifier(
    n_estimators=500,
    learning_rate=0.05,
    max_depth=5,
    random_state=156,
    eval_metric='auc',
    tree_method='gpu_hist',
    early_stopping_rounds=100,
    gpu_id=0
)

xgb_clf.fit(
    X_tr, y_tr,
    eval_set=[(X_val, y_val)],
    verbose=False
)

roc_score = roc_auc_score(y_test, xgb_clf.predict_proba(X_test)[:, 1])
print(f"ROC AUC Score (이상치 제거 + 언더샘플링): {roc_score:.4f}")
```

이상치 제거 및 SMOTE

```
cust_train_df = pd.read_csv('./santander-customer-satisfaction/train.csv', encoding='latin-1')
cust_test_df = pd.read_csv('./santander-customer-satisfaction/test.csv', encoding='latin-1')

cust_train_copy_df = cust_train_df.copy()
cust_test_copy_df = cust_test_df.copy()

numeric_cols = cust_train_copy_df.select_dtypes(include=['int64', 'float64']).columns.drop('TARGET')
```

```
for col in numeric_cols:
    Q1 = cust_train_copy_df[col].quantile(0.25)
    Q3 = cust_train_copy_df[col].quantile(0.75)
    IQR = Q3 - Q1
    lower_bound = Q1 - 1.5 * IQR
    upper_bound = Q3 + 1.5 * IQR
    median = cust_train_copy_df[col].median()

    cust_train_copy_df.loc[
        (cust_train_copy_df[col] < lower_bound) | (cust_train_copy_df[col] > upper_bound),
        col
    ] = median


cust_train_copy_df.drop('ID', axis=1, inplace=True)
if 'ID' in cust_test_copy_df.columns:
    ids = cust_test_copy_df['ID']
    cust_test_copy_df.drop('ID', axis=1, inplace=True)
else:
    ids = cust_test_copy_df.index


X_features = cust_train_copy_df.drop('TARGET', axis=1)
y_target = cust_train_copy_df['TARGET']


smote = SMOTE(random_state=42)
X_resampled, y_resampled = smote.fit_resample(X_features, y_target)


X_train, X_test, y_train, y_test = train_test_split(
    X_resampled, y_resampled,
    test_size=0.3,
    random_state=156,
    stratify=y_resampled
)

X_tr, X_val, y_tr, y_val = train_test_split(
    X_train, y_train,
    test_size=0.3,
    random_state=0
)

xgb_clf = XGBClassifier(
    n_estimators=500,
    learning_rate=0.05,
    max_depth=5,
    random_state=156,
```

```
        eval_metric='auc',
        tree_method='gpu_hist',
        early_stopping_rounds=100,
        gpu_id=0
)

xgb_clf.fit(
        X_tr, y_tr,
        eval_set=[(X_val, y_val)],
        verbose=False
)

roc_score = roc_auc_score(y_test, xgb_clf.predict_proba(X_test)[:, 1])
print(f"ROC AUC Score (이상치 제거 + SMOTE): {roc_score:.4f}")
```